

AI, Human Cognition and Knowledge Collapse

Cómo funciona el mecanismo, qué mide el bienestar y dónde falla la robustez

Belén Vásquez

Septiembre de 2026

Acemoglu, Kong & Ozdaglar (2026), NBER WP 34910

github.com/sbvasquezg-ux/ai-04-acemoglu

Pregunta y ruta del argumento

Pregunta central. ¿Puede una IA que mejora las decisiones privadas terminar destruyendo el conocimiento público que hace valiosas esas decisiones?

1. Definir qué representan X , Y , e y τ_A .
2. Mostrar por qué X complementa el esfuerzo y τ_A lo sustituye.
3. Seguir el efecto de menor esfuerzo sobre X_{t+1} .
4. Separar el beneficio inmediato de la pérdida dinámica de bienestar.
5. Probar qué parte del colapso depende de supuestos de frontera.

Objetivo de la presentación: reconstruir el resultado y defender una objeción de robustez, no resumir todo el paper.

Fuente: Introducción y §§3–5, pp. 2–33.

La producción impone complementariedad extrema

$$\Delta_G = f(1, 0) - f(0, 0), \quad \Delta_I = f(0, 1) - f(0, 0), \quad \Delta_X = f(1, 1) - f(1, 0) - f(0, 1) + f(0, 0).$$

Assumption 1: $\Delta_I = 0$, $\Delta_X > 0$; además $\Delta_G + \Delta_I + \Delta_X = 1$. El ejemplo Leontief fija $\Delta_G = \Delta_I = 0$, $\Delta_X = 1$.

Contexto específico sin conocimiento general no añade output: esta frontera vuelve posible bienestar cero.

Fuente: §3.1, pp. 8–10.

Información y dominios

$$\theta_{t+1} = \theta_t + \epsilon_t,$$

$$\theta_{i,t} \sim N(0, \sigma^2),$$

$$s_{i,t}^A \sim N(\theta_{i,t}, \tau_A^{-1}),$$

$$\epsilon_t \sim N(0, \Sigma^2),$$

$$s_{i,t}^H \sim N(\theta_{i,t}, (\lambda_I e)^{-1}),$$

$$s_t^C \sim N(\theta_t, (\lambda_G E_t)^{-1}).$$

$$e \geq 0, \tau_A \geq 0, \lambda_I, \lambda_G > 0, \alpha > 1, I \in [1, M].$$

Fuente: §3.1, pp. 8–12.

Problema estático y CPO

$$U = f(0, 0) + G(X)\Delta_G + G(X)G(\sigma^{-2} + \lambda_I e + \tau_A)\Delta_X - e^\alpha / \alpha.$$

$$U_e = \Delta_X G(X) \lambda_I g(Y) - e^{\alpha-1} = 0.$$

- ▶ e : esfuerzo cognitivo elegido por la persona; X : precisión del conocimiento general heredado.
 - ▶ $Y = \sigma^{-2} + \lambda_I e + \tau_A$: precisión contextual total; τ_A es la parte que entrega la IA.
 - ▶ $G(z)$ es la probabilidad de una decisión correcta; e^α / α es el costo de pensar.
- g decrece y el costo marginal crece: máximo único. Para $X > 0$ es interior; para $X = 0$, $e^* = 0$.

Fuente: Ecuaciones (4)–(6), §3.5 y nota 4, pp. 12–15.

Observación 1: prueba y frontera

$$U_{eX} = \Delta_X \lambda_I g(X) g(Y) > 0, \quad U_{e\tau_A} = \Delta_X G(X) \lambda_I g'(Y) < 0.$$

- ▶ $U_{eX} > 0$: X y e son complementos; más base común vuelve más productivo el esfuerzo individual.
- ▶ $U_{e\tau_A} < 0$: τ_A y e son sustitutos; la IA aporta la precisión que la persona obtendría pensando.
- ▶ Menos e también reduce la señal que la sociedad agrega en X_{t+1} , efecto que el individuo no internaliza.
- ▶ En $X = 0$, la segunda desigualdad es cero y la primera derivada no es finita.

Fuente: Observación 1, §3.4, pp. 13–14; nota 4, p. 15.

Del esfuerzo al estado estacionario

$$X_{t+1} = F(X_t) = [\Sigma^2 + (X_t + \lambda_G Ie(X_t, \tau_A))^{-1}]^{-1}.$$

- ▶ $E_t = Ie_t$ es esfuerzo total; $\lambda_G E_t$ mide cuánta precisión pública produce la cohorte.
- ▶ $F(X_t)$ transforma el conocimiento actual y la nueva señal en el stock del próximo período.
- ▶ Si $1/(\alpha - 1) > 4$, el esfuerzo responde mucho a incentivos y cero es localmente estable; si es menor que cuatro, cero es inestable.
- ▶ La igualdad no queda clasificada por Lemma 2.

Fuente: Ecuaciones (7)–(9), Lemma 2, pp. 16–18.

Colapso completo requiere más que Observación 1

Para elasticidad mayor que cuatro, puede haber tres steady states. Si $\tau_A > \tau_A^c$, queda solo $\bar{X} = 0$ y es globalmente estable.

- ▶ Atomisticidad: nadie internaliza la señal pública.
- ▶ $\Delta_I = 0$: la señal privada sola vale cero.
- ▶ Sin flujo autónomo: $F(0) = 0$.

Fuente: Proposición 5, §§3.7–3.8, pp. 19–23.


Bienestar: una derivada con dos signos

$$\begin{aligned}\bar{U} &= G(\bar{X})\Delta_G + G(\bar{X})G(\bar{Y})\Delta_X - \bar{e}^\alpha/\alpha, \\ \bar{U}_{\tau_A} &= \underbrace{g(\bar{Y})G(\bar{X})\Delta_X}_{DE \geq 0} + \underbrace{G_{\tau_A}(\bar{X})[\Delta_G + G(\bar{Y})\Delta_X]}_{-IE \leq 0}.\end{aligned}$$

- DE : mejor consejo aumenta hoy la probabilidad de elegir correctamente.
- IE : una mayor τ_A reduce esfuerzo, agregación y el stock estacionario $\bar{X}$; por eso $G_{\tau_A}(\bar{X}) < 0$.
- El signo total depende de cuál de los dos canales domina.

Fuente: Ecuación (10), §4.3, pp. 24–26.

Lectura de la curva de bienestar



- **Eje horizontal:** τ_A , precisión de la recomendación agéntica.
- **Eje vertical:** $\bar{U}^+$, utilidad neta en el estado estacionario alto.
- Antes de τ_A^* domina el beneficio directo.
- Después domina la pérdida de conocimiento general y la utilidad cae estrictamente.
- Assumption 2 evita cambios múltiples de signo.

La figura no dice que “la IA empeora el bienestar” en general. Dice que, dentro del modelo y a partir de un umbral, una mejora marginal de precisión destruye más valor dinámico del que crea hoy.

Fuente: Propositiones 10–11, pp. 26–27; simulación propia.

Las seis relajaciones: qué sí está en el PDF

Candidato	Resultado de auditoría
IA agrega general	Relajado en §5.1; sobrevive solo si $\eta < 1/[2(\alpha - 1)]$.
Datos sintéticos	Relajado en §5.2; $\tau_{syn} > 0$ elimina el steady state cero.
$\tau_A(X)$	No modelado; signo total ambiguo.
CES	No modelado; la tabla binaria con $\Delta_I = 0$ no es CES.
Entrada/especialistas	No hay precio ni heterogeneidad de costo; simetría impuesta.
Aprendizaje usando IA	No hay stock individual persistente; cohortes cortas e idiosincrasia i.i.d.

Fuente: §§3.1, 5.1–5.3, pp. 8–12 y 30–33.

Comparación con Quispe–Xu (2026)

- ▶ El portafolio de lenguajes crece persistentemente tras adopción.
- ▶ El patrón sobrevive al excluir commits coescritos por el agente.
- ▶ Es compatible con aprendizaje y complementariedad, no prueba causal definitiva por adopción voluntaria.

Añadir aprendizaje persistente rompe la equivalencia entre “menos esfuerzo hoy” y “menos capacidad humana mañana”.

Fuente: Quispe & Xu (2026), abstract/resultados reportados; contraste propio con §3.1 de AKO.

Veredicto y comprobación manuscrita

Sobrevive

Más precisión contextual puede reducir esfuerzo, conocimiento general y bienestar; con elasticidad alta puede haber trampas y path dependence.

No sobrevive sin condiciones

“Todo conocimiento desaparece”: con $\Delta_I > 0$ o $\tau_{syn} > 0$, cero deja de ser punto fijo.

Enunciado defendible: la IA puede desplazar la economía hacia conocimiento bajo; cero exacto es una propiedad del baseline.

Fuente: Assumption 1 y Proposiciones 5, 10–11 y 15, pp. 9, 21–27 y 32.

1. Assumption 1 (3.4, Obs 1). Bajo el supuesto 1 ($\Delta_I = 0$, $\Delta_e > 0$), el estado colapso tiene $\bar{x} = 0$ exactamente.

2. CPO del paper, con $y = \sigma^2 = \lambda_e \bar{e} + \tau_e$.
 $\Delta_e G(x) \lambda_e g(y) = e^{K-1}$
El lado izquierdo es el beneficio marginal, MB ($\bar{e}; x, \tau_e$)

3. En $\bar{x} = 0$, como $G(0) = 0$:
 $MB(\bar{e}; 0, \tau_e) = 0 \rightarrow e^{K-1} = 0 \quad \forall \tau_e$

4. Ley de movimiento $\bar{x}' = \Phi(\bar{e}) + \tau_{syn}$, con $\Phi(0) = 0$. Bajo los supuestos del paper $\tau_{syn} = 0$, luego $\bar{x}' = 0$, uno es punto fijo y observable.

5. Siendo $\Delta_I > 0$, la utilidad gana el término $G(y) \Delta_I$ y la CPO para α :
 $[\Delta_e G(x) + \Delta_I] \lambda_e g(y) = e^{K-1}$

6. Evalúa en $\bar{x} = 0$ y $\bar{e} = 0$:
 $MB(0; 0, \tau_e) = \Delta_I \lambda_e g(\sigma^2) + \tau_e > 0 = e^{K-1}$ en $\bar{e} = 0$
MB decrece en $\bar{e}$ (porque $g' < 0$) y e^{K-1} crece (porque $\alpha > 1$).
Se cruzan una sola vez, y el cruce está en $e^*(0; \tau_e) > 0$.
Entonces, $\bar{x}' = \Phi(e^*) > 0$ y cero deja de ser punto fijo.

7. Segunda vía, independiente. Con agregación sintética, $\tau_{syn} > 0$ (3.2, Prop 15): $\bar{x}' \geq \tau_{syn} > 0$ aún si $\bar{e}^* = 0$. No hace falta tocar Δ_I .

8. Conclusión: El estado no resuelve $\bar{x} = \Phi(e^*(\bar{x}, \tau_e)) + \tau_{syn}$, con $\bar{x} > 0$ si $\Delta_I > 0$ o $\tau_{syn} > 0$. El colapso exactamente a cero equivale a $\Delta_I = 0$ y $\tau_{syn} = 0$: 2 condiciones de filo al naufragio, no un resultado robusto. Lo autoralista es un estado de conocimiento bajo.

Evidencia aportada por la estudiante.