

AI, Human Cognition and Knowledge Collapse

Pregunta, mecanismo, bienestar y una objeción de robustez

Belén Vásquez

Universidad del Pacífico

Septiembre de 2026

Acemoglu, Kong & Ozdaglar (2026), NBER WP 34910

github.com/sbvasquezg-ux/ai-04-acemoglu

1 · Pregunta y problema del agente

Objetivo. Explicar por qué una IA más precisa puede reducir el esfuerzo humano y, con él, el conocimiento general que beneficia a todos.

$$\max_{e \geq 0} U = f(0, 0) + G(X)\Delta_G + G(X)G(Y)\Delta_X - \frac{e^\alpha}{\alpha}, \quad Y = \sigma^{-2} + \lambda_I e + \tau_A.$$

$$\underbrace{\Delta_X G(X) \lambda_I g(Y)}_{MB(e; X, \tau_A)} = e^{\alpha-1}.$$

- ▶ e : esfuerzo cognitivo; X : precisión del conocimiento general heredado; Y : precisión contextual total.
- ▶ τ_A : precisión del consejo de IA; $\lambda_I e$: precisión creada por el esfuerzo; $\alpha > 1$: curvatura del costo.
- ▶ $G(z)$: probabilidad de decidir correctamente con precisión z ; $g(z) = G'(z) > 0$.

Mecanismo: X eleva el beneficio marginal de pensar; τ_A mejora Y sin esfuerzo y reduce ese beneficio. El agente no internaliza que su esfuerzo también alimenta el conocimiento público futuro.

Fuente: PDF 20-02-2026, §§3.1–3.5, pp. 8–15; ecuaciones (4)–(6).

2 · Observación 1: complemento y sustituto

Condiciones: señales gaussianas independientes, $\lambda_I > 0$, costo e^α/α con $\alpha > 1$, $\Delta_I = 0$, $\Delta_X > 0$ y solución interior con $X, Y > 0$.

$$U_{eX} = \Delta_X \lambda_I g(X) g(Y) > 0, \quad U_{e\tau_A} = \Delta_X G(X) \lambda_I g'(Y) < 0.$$

Lectura económica


$U_{eX} > 0$: más conocimiento general aumenta el retorno de una hora adicional de esfuerzo. $U_{e\tau_A} < 0$: una recomendación más precisa reduce ese retorno porque ya aporta precisión contextual. Con costo convexo, $e_X^* > 0$ y $e_{\tau_A}^* < 0$.

Por qué importa: menos e hoy implica menos señal pública agregada y menor X mañana. La observación estática abre el canal dinámico del colapso. En $X = 0$, sin embargo, $e^* = 0$ y la desigualdad estricta deja de estar bien definida.

Fuente: §3.4–3.5, pp. 13–15; Observaciones 1–2 y nota 4.

3 · Bienestar: cómo leer el gráfico

$$\frac{\partial \bar{U}^+}{\partial \tau_A} = \underbrace{g(\bar{Y}_h)G(\bar{X}_h)\Delta_X}_{DE \geq 0} + \underbrace{\frac{\partial G(\bar{X}_h)}{\partial \tau_A} [\Delta_G + G(\bar{Y}_h)\Delta_X]}_{-IE \leq 0}.$$



- **Eje x:** τ_A , precisión exógena de la recomendación de IA. Moverse a la derecha significa mejor consejo.
- **Eje y:** $\bar{U}^+$, utilidad neta en el estado estacionario alto.
- **Tramo ascendente:** domina el efecto directo de acertar más hoy.
- **Tramo descendente:** domina la pérdida de X causada por menor esfuerzo y agregación.

Interpretación: curva de U invertida. El bienestar sube hasta τ_A^* y luego cae estrictamente. No mide utilidad descontada ni distribución.

Fuente: Ecuación (10), §4.3 y Proposiciones 10–11, pp. 24–27; cálculo propio.

4 · Objeción: el cero exacto depende del baseline

Qué cuestiono. El paper demuestra que $\bar{X} = 0$ puede ser absorbente, pero ese resultado necesita simultáneamente:

1. $\Delta_I = 0$: el conocimiento específico solo no produce valor.
2. $\tau_{syn} = 0$: la IA no crea un flujo autónomo de conocimiento general.
3. Agentes atomísticos y homogéneos: nadie internaliza la externalidad y no quedan especialistas activos.

Relajaciones: con $\tau_{syn} > 0$, $F_{syn}(0) > 0$ (Prop. 15); con $\Delta_I > 0$, pensar conserva retorno privado en $X = 0$. Quispe–Xu aporta evidencia compatible con aprendizaje al usar IA, otro canal que preservaría capacidad humana.

Veredicto. Sí sobrevive el riesgo de una economía con poco conocimiento general. La desaparición exacta requiere condiciones de filo de navaja; el resultado robusto es “conocimiento bajo”, no necesariamente cero.

Fuente: §§5.1–5.2, pp. 30–32; Assumption 1, p. 9; hand/README.md.

1. Alternativa (3.4, Que 1). Bajo el supuesto 1 ($\Delta_I = 0$, $\Delta_e > 0$), el equilibrio coincide entre $\bar{X} = 0$ exactamente.

2. CPO del paper, con $y = a^1 - \tau_e e + \tau_e$.
 $\Delta_e G(x) \lambda, g(y) = e^{a^1 - 1}$
El caso relevante es la función marginal, $MB(x, \tau_e)$.

3. En $X = 0$, como $G(0) = 0$:
 $MB(0, 0, \tau_e) = 0 \rightarrow e^{a^1 - 1} \tau_e = 0 \quad \forall \tau_e$

4. Sea el mínimo $X^* = \Phi(e^*) = \tau_{syn}$, con $G(0) = 0$. Bajo los supuestos del paper $\tau_{syn} = 0$, luego $X^* = 0$, pero el punto tipo y asociado.

5. Sea $\Delta_e > 0$, la utilidad gana el término $G(y) \Delta_e$ y la CPO para 0:
 $[\Delta_e G(x) + \Delta_e] \lambda, g(y) = e^{a^1 - 1}$

6. Evalúa en $X = 0$ y $e = 0$:
 $MB(0, 0, \tau_e) = \Delta_e \lambda, g(0^+ + \tau_e) > 0 = e^{a^1 - 1}$ en $e = 0$
MB decrece en e (porque $g' < 0$) y $e^{a^1 - 1}$ crece (porque $a^1 > 1$), se cruzan una sola vez, y el cruce está en $e^*(0, \tau_e) > 0$. Entonces $X^* = \Phi(e^*) > 0$ y cero está a la izquierda de X^* .

7. Segunda vía, independiente. Con agregación sin fines $\tau_{syn} > 0$ (s. 2, Prop. 15): $X^* \geq \tau_{syn} > 0$ aún si $e^* = 0$. No hace falta tocar Δ_e .

8. Conclusión. El aprendizaje humano $\bar{X} = \Phi(e^*(X, \tau_e)) + \tau_{syn}$, con $X \geq 0$ y $\Delta_e > 0$ y $\tau_{syn} > 0$. El equilibrio exactamente a cero equivale a $\Delta_e = 0$ y $\tau_{syn} = 0$. 7 conclusiones de filo de navaja, no un resultado robusto. Lo anterior es un estudio del conocimiento bajo.

Verificación manuscrita aportada por la estudiante.